Desafio Natura:
Previsão de Demanda e Otimização da Distribuição

Terceira apresentação parcial

Luiza Santos, Leonardo Ferreira, Leonardo Leal, Mateus Martins,
Layza Carvalho, Ana Clara Felizardo, Tasso Canellas

UNIFESP

10 de novembro de 2026

Sumário

1. Contextualização
2. Desenvolvimentos
3. Resultados
4. Próximos Passos

Contextualização

- **Estrutura comercial:** setores distribuídos em blocos e subblocos, com diferentes datas de abertura dos ciclos;
- **Comportamento da demanda:** a data de abertura influencia o volume e a distribuição diária dos pedidos;
- **Desequilíbrio operacional:** concentração de aproximadamente 45% dos pedidos no Bloco 2, gerando picos de demanda;
- **Restrições logísticas:** necessidade de respeitar a capacidade dos centros de distribuição e as regras operacionais.

Proposta de solução

Desenvolvimento de duas ferramentas complementares para **previsão de demanda** e **otimização da distribuição**.

1. Previsão de demanda

- Previsão da **demanda diária** dos setores;
- Estimativa do **volume e distribuição temporal** dos pedidos nos ciclos comerciais.

2. Otimização da distribuição

- **Alocação dos setores** em blocos e subblocos;
- **Balanceamento da demanda**, respeitando a capacidade dos CDs e as regras de negócio.

Recapitulando – Demanda

- Limpeza e tratamento dos dados;
- Adição de variáveis temporais e regionais para previsão de demanda;
- Decomposição da previsão em duas componentes:
  - **Level:** demanda total por ciclo;
  - **Shape:** distribuição percentual da demanda ao longo do ciclo.
- Avaliação de diferentes modelos de previsão:
  - **Séries temporais:** ARIMA e ETS;
  - **Machine Learning:** LightGBM.

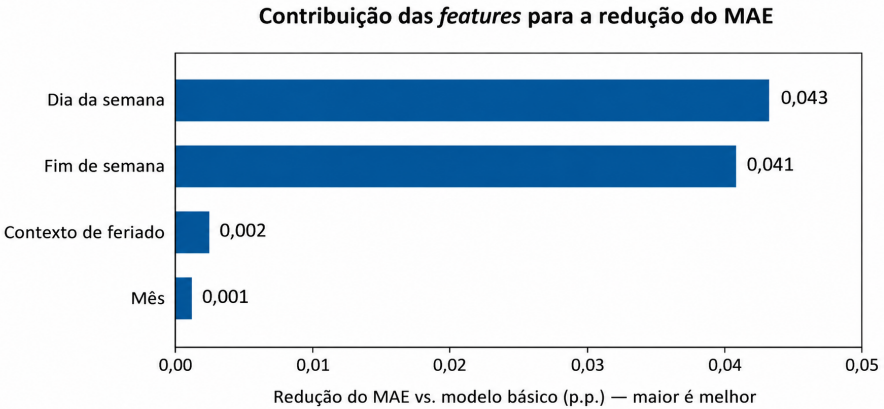
Recapitulando – Otimização

Foram adotadas duas abordagens para a resolução do problema de otimização:

- **Modelo exato:** resolução via solver Gurobi;
- **Metaheurística:** Simulated Annealing (SA).

Shape – Resultados

O modelo **LightGBM** apresentou o melhor desempenho na previsão do *Shape*, alcançando um **MAE de 6,35%**.



Resultados - Level

Comparação dos modelos de previsão da demanda total por ciclo, considerando diferentes níveis de granularidade.

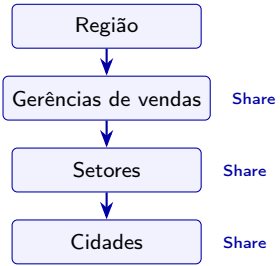
Nível	Modelo	MAE	WMAPE	Bias (%)
Setor	Média móvel (5 ciclos)	1.958,28	43,46%	-6,94%
Setor	**LightGBM**	**1.892,37**	**42,01%**	**2,48%**
Setor-cidade	Média móvel (5 ciclos)	235,32	60,68%	-19,92%
Setor-cidade	**LightGBM**	**222,22**	**57,26%**	**-17,18%**

Modelos por hierarquia

Foram testados dois modelos de previsão hierárquica.

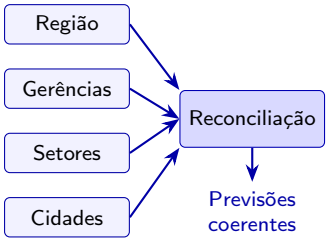
Modelo por compartilhamento

- Previsão no nível mais agregado;
- Distribuição para os níveis inferiores conforme o *share* de participação.



Modelo por reconciliação

- Previsões independentes em cada nível;
- Ajuste das previsões para garantir coerência entre os níveis.



Resultados – Modelo por Hierarquia

Nível	Modelo	MAE	WMAPE	Bias (%)
Região	Média móvel (5 ciclos)	40.248	11,73%	-7,17%
Região	**ETS + LightGBM (Rec.)**	**36.505**	**10,64%**	**-0,66%**
Região	Compartilhamento	38.659	11,27%	-6,52%
Gerência	Média móvel (5 ciclos)	12.358	16,66%	-7,17%
Gerência	**ETS + LightGBM (Rec.)**	**11.068**	**14,92%**	**-0,66%**
Gerência	Compartilhamento	11.848	15,97%	-6,52%
Setor	Média móvel (5 ciclos)	1.958	43,46%	-6,94%
Setor	ETS + LightGBM (Rec.)	1.860	41,31%	-0,66%
Setor	**Compartilhamento**	**1.851**	**41,09%**	**-6,52%**
Setor-cidade	Média móvel (5 ciclos)	235	60,68%	-19,92%
Setor-cidade	ETS + LightGBM (Rec.)	222	57,20%	-15,67%
Setor-cidade	**Compartilhamento**	**220**	**57,04%**	**-21,72%**

- O aumento da **granularidade** está associado a **maiores erros percentuais** de previsão.

Resultados – Modelos por Hierarquia

E se pararmos no nível de gerência?

Nível	Modelo	MAE	WMAPE	Bias (%)
Região	Média móvel (5 ciclos)	40.248	11,73%	-7,17%
Região	**ETS + LightGBM (Rec.)**	**35.555**	**10,36%**	**-2,46%**
Região	Compartilhamento	38.659	11,27%	-6,52%
Gerência	Média móvel (5 ciclos)	11.915	16,06%	-7,17%
Gerência	**ETS + LightGBM (Rec.)**	**11.114**	**14,98%**	**-2,46%**
Gerência	Compartilhamento	11.615	15,66%	-6,52%
Gerência-cidade	Média móvel (5 ciclos)	248	53,06%	-5,40%
Gerência-cidade	ETS + LightGBM (Rec.)	235	50,27%	-14,78%
Gerência-cidade	**Compartilhamento**	**231**	**49,74%**	**-17,90%**

- A **reconciliação** apresentou os menores erros em região e gerência, enquanto o **compartilhamento** obteve o melhor WMAPE em gerência-cidade.

Simulated Annealing em escala

Comparação de configurações

Configuração	*Gap*	Tempo
Amplitude, 200 mil it.	8,3%	27 s
Amplitude, 1 mi it.	4,2%	155 s
Pico+desvio, 200 mil	11,0%	$\sim$1,8$\times$ (de 27 s)

- Mais iterações reduzem o *gap* (8,3% $\rightarrow$ 4,2%)
- **Pico+desvio** reduz o desvio da carga em 1–3%, mas piora o *gap* da amplitude; cada energia exige **calibração própria**

Relax-and-Fix + Fix-and-Optimize

- Matheurística testada como alternativa ao MIP, com janelas de CDs
- Sintético (até 800 setores, 7 ciclos): viável e a $\leq$0,08% do ótimo, mas **não mais rápida** que o MIP com Gurobi
- Dados reais (Gurobi): 16.995 em 9,5 min, **3,5% pior** que o MIP em 10 s
- Só compensa com HiGHS quando a capacidade é apertada e o MIP não acha solução viável
- **Conclusão:** não adotada; parâmetros ainda sem calibração

MIP com tempo limitado

Método	Tempo	Objetivo	*Gap**
MIP	10 s	16.425	1,1%
MIP	60 s	16.403	0,9%
MIP	10 min	**16.389**	0,7%
SA	$\sim$1 s	34.900	114%

*contra o limite inferior do Gurobi (MIP: o da própria rodada; SA: 16.282, rodada de 2 h). Dados reais: 568 setores, 6 ciclos, 1 semente.

- O MIP chega a **1,1% do limite inferior em 10 s**; os 10 min seguintes melhoram só 0,2%
- O *warm-start* do SA não muda o MIP

End-to-end com dados reais

Melhora sobre o As-Is (amplitude diária)

Previsão	Prevista	**Realizada**
Hier. (setor)	26,7 ± 2,4%	**18,1 ± 2,5%**
Hier. (gerência)	26,3 ± 2,4%	**17,7 ± 3,6%**
Média	26,6 ± 2,5%	**18,6 ± 2,8%**
Todas (30 exec.)	26,5 ± 2,4%	**18,1 ± 2,9%**
Mín–máx	23,2–31,1%	9,3–24,0%

Média ± desvio em 10 sementes por previsão; 113 setores movidos.

- 568 setores, 20 ciclos de histórico, 6 de horizonte **retido**; *churn* $\leq 20\%$
- **Realizada** = reavaliada na demanda real do horizonte

Qual método usar

- **Recomendação:** MIP com limite de tempo
- Limite ajustado ao tempo disponível
- 1,1% do limite inferior em 10 s
- SA: *fallback* rápido

Próximos Passos

- **Refinamento dos modelos:** aprimoramento das abordagens de previsão de demanda e otimização;

- **Elaboração do relatório final:** consolidação da metodologia, dos resultados e das principais conclusões do projeto.